國立中興大學

電機工程學系

從繼承到創新：應用於深度強化學習之雙通道遺傳演算法

From Inheritance to Innovation: A Dual-Channel Genetic Algorithm for Deep Reinforcement Learning

研究生:陳奕安、吳驊昀

指導教授: 蔡曉萍

中華民國 114 年 10

摘要

深度神經演化（Deep Neuroevolution）在優化深度神經網路時，常因權重排列的不對齊導致傳統交配機制失效，進而引發災難性遺忘或模型功能崩潰。針對此一難題，本研究提出一種基於雙通道融合網路（DCFN）的新型結構化交配算子。此算子透過結構化拼接雙親策略網路的特定神經元區塊，構建出兼具負責保留知識的「純淨通道」與負責探索的「交叉通道」之子代架構，旨在實現強化學習模型對雙親關鍵行為基因的精準繼承，並同時促進策略創新 。

為確保子代模型在交配後具備穩定的可訓練性與演化能力，本研究建立了一套協同演化訓練框架。該框架整合了五大關鍵機制：(1) 交叉通道初始化以穩定演化初期狀態；(2) 純淨通道凍結以嚴格保護親代核心知識；(3) 結合軟、硬目標的離線知識蒸餾以快速對齊行為特徵；(4) 基於**梯度掛鉤（Gradient Hook）**的差異化學習率策略，以精細協調繼承與學習的參數更新步調；以及(5) 課程式線上微調以提升環境泛化能力。此協同機制有效克服了融合模型常見的梯度不穩與策略偏移問題。

本研究於 BipedalWalker 環境中進行 0 至 5 代的多世代演化實驗，並探討族群規模對演化動態之影響。實驗結果顯示，DCFN 算子能穩定產生性能顯著優於親代的子代模型，不僅平均報酬大幅提升，標準差亦顯著降低，展現出優異的魯棒性。族群分析進一步指出，較大的族群規模能有效維持基因多樣性並延緩過早收斂，使子代在多代演化中展現持續優化的潛力。系統性消融研究亦證實，離線蒸餾、差異化學習率與交叉通道歸零是驅動此演化框架成功的關鍵組件。綜上所述，本研究證實了雙通道交配算子能同時達成高效的知識繼承與策略創生，為演化式強化學習提供了具潛力的新架構 。綜合上述設計，本研究最終形成了一套可於多世代持續運作的雙通道演化式強化學習架構（DCFN-GA)，有效解決深度神經演化在權重交配上的語意不對齊問題，並展現實證上的策略創生能力。

Contents

第壹章 緒論.....7

1.1 研究目的.....7

1.2 研究目的.....7

1.3 研究架構與流程.....8

1.3.1 訓練父母專家模型.....9

1.3.2 模型交配與融合階段.....9

1.3.3 子代訓練與蒸餾階段.....9

1.3.4 模型測試與消溶性實驗.....9

第貳章 文獻探討.....10

2.1 ppo 演算法.....10

2.2 GA, 遺傳演算法:.....10

2.3 神經演化.....11

2.4 模型合併與知識蒸餾:.....11

第參章 研究方法.....12

3.1 族群初始化.....13

3.2 親代選擇（Parent Selection）.....13

3.3 結構化交配與子代增強.....13

3.3.1 雙通道融合網路 14

3.3.2 交叉通道初始化 15

3.3.3 離線知識蒸餾 15

3.3.4 線上學習: 15

3.3.5 自動化超參數優化（HPO） 16

第肆章 實驗設計與結果分析 17

4.1 實驗環境與設定: 17

4.1.1 硬體與軟體環境 17

4.1.2 訓練環境與模型架構 17

4.1.3 參數設定 18

4.1.4 評估方法 18

4.2 冠軍模型效能評估 19

4.3 系統性消融研究 20

4.4 泛化能力分析 21

4.5 行為分析 24

4.6 多世代演化結果分析 26

第伍章 結論與未來工作 29

5.1 結論 29

5.2 研究貢獻 29

5.3 未來展望 29

第陸章 參考資料 30

圖目錄

圖 1.1 研究架構與流程 8

圖 3.1 整體架構 12

圖 4.2 冠軍模型效能評估 19

圖 4.3 模型與訓練效果比較 20

圖 4.4 a 度 0.2 模型交配與訓練效果比較 21

圖 4.4c 難度 0.2 模型交配與訓練效果比較 21

圖 4.4 b 難度 0.4 模型交配與訓練效果比較 21

圖 4.4d 難度 0.4 模型交配與訓練效果比較 21

圖 4.4 d 難度 0.8 模型交配與訓練效果比較 22

圖 4.4d 難度 0.8 模型交配與訓練效果比較 22

圖 4.4 c 難度 0.6 模型交配與訓練效果比較 22

圖 4.4c 難度 0.6 模型交配與訓練效果比較 22

圖 4.4e 難度 0.9 模型交配與訓練效果比較 23

圖 4.4e 難度 0.9 模型交配與訓練效果比較 23

圖 4.4f 難度 1.0 模型交配與訓練效果比較 23

圖 4.4f 難度 1.0 模型交配與訓練效果比較 23

圖 4.6.3.2:動作維度 **2** 分佈比較.....24

圖 4.6.3.1:動作維度 **1** 分佈比較.....24

圖 4.6.3.4:動作維度 **4** 分佈比較.....25

圖 4.6.3.3:動作維度 **3** 分佈比較.....25

圖 4.6.1:Ga 成功率比較 26

圖 4.6.3:個世代獎勵分布比較.....27

圖 4.6.2:個世代標準差比較 27

圖 4.6.2: 族群穩定性比較圖 28

圖 4.6.2: 族群規模表現比較圖 28

國立中興大學進修學士班
NCHU Continuing Bachelor Program
Since 1968

第壹章 緒論

1.1 研究目的

深度強化學習雖能在多項控制任務中取得優異表現，但仍面臨訓練成本高、缺乏策略重用等問題。為提升效率，本研究引入遺傳演算法於權重空間進行模型融合。然而，既有專家模型之間因神經元語意不對齊而難以直接交配，易造成子代崩潰。為此，本研究提出雙通道結構化交配運算子並結合蒸餾與微調的協同演化流程，使子代能穩定繼承並融合父母策略，進而生成更高性能的策略模型。

1.2 研究目的

本研究旨在解決深度強化學習模型於權重交配中因語意不對齊而導致策略崩潰的問題，目標是建立一套可在多代演化中穩定繼承並創新策略的神經演化框架。具體而言：

(1) **設計結構化交配算子**：提出雙通道融合網路（DCFN），以結構化方式保留雙親權重並避免排列問題；

(2) **建立協同訓練流程**：整合初始化、蒸餾、梯度調控與課程式學習，以提升子代早期穩定性與後期優化能力；

(3) **驗證演化效益**：於 BipedalWalker 進行多代測試，比較子代與親代之性能、穩定性與族群收斂特性；

(4) **分析內部機制**：透過權重與行為分析，確認子代能融合並超越親代策略。

1.3 研究架構與流程

本研究的整體流程如圖 1.1 所示，主要可分為四個階段：

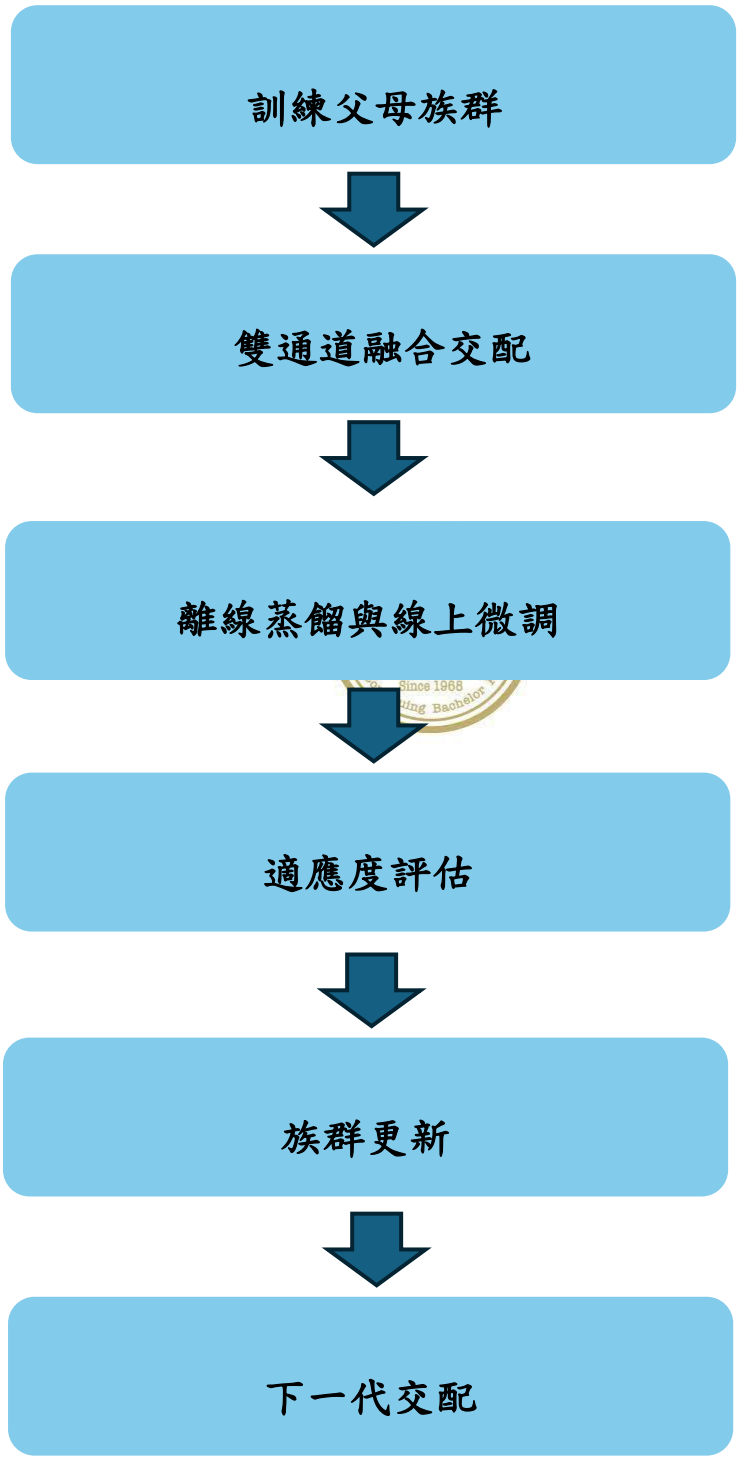

圖 1.1 研究架構與流程

1.3.1 訓練父母專家模型

本研究首先於自訂 BipedalWalkerCustom 環境中，以 PPO 演算法並搭配不同隨機種子訓練多個具策略差異性的專家模型。構成（GA）初始族群的父母個體。後續演化流程以此族群為基礎，形成連續多代的演化循環。

1.3.2 模型交配與融合階段

為避免傳統權重交配造成策略崩潰，本研究提出雙通道融合（DCFN）作為結構化交配算子。DCFN 將父母模型的權重分為：

- **純淨通道**：直接繼承父母模型的核心特徵與決策模式。
- **交叉通道**：負責融合雙親之互補策略訊息，

此交配程序於每一世代重複進行，使族群在交配與選擇之間逐步演化。

1.3.3 子代訓練與蒸餾階段

為了使子代能有效整合父母的決策特徵本研究採兩階段訓練:

- 策略蒸餾 ： 凍結純淨通道僅更新交叉通道
- 線上微調： 子代與環境互動進行 RL 微調；純淨通道採軟凍結以保留父母知識，交叉通道則負責探索與創新。完成此流程後，子代將依適應度排序，表現最佳進入下一世代作為父母。

1.3.4 模型測試與消溶性實驗

最終模型於多難度（0.0–1.0）與 100 個隨機種子下進行測試，並以平均報酬、標準差、策略相似度、動作分布與權重差異等指標評估：

- 子代對父母策略之繼承程度
- 交叉通道帶來的策略創新
- 子代在高難度場景中的泛化能力
- 族群多樣性與 GA 收斂特性

第貳章 文獻探討

2.1 ppo 演算法

PPO 是目前深度強化學習中最穩定的策略梯度方法之一。其目標是透過調整策略參數 θ 來最大化期望回報：

$$J(\theta) = \mathbb{E}_{\mathcal{T}\sim\pi\theta}\left[\sum_t \gamma^t r_t\right]$$

為避免策略更新幅度過大導致訓練不穩定，PPO 引入「剪裁策略比值」：：

$$L^{CLIP}(\theta) = \mathbb{E}_t\left[min\left(r_t(\theta)\hat{A}_t, clip(r_t(\theta), 1-\epsilon, 1+\epsilon))\hat{A}_t\right)\right]$$

其中$r_t(\theta)$=$\frac{\pi_\theta(a_t|s_t)}{\pi_{\theta old}(a_t|s_t)}$，PPO 兼具 穩定性、高樣本效率與易調參，本研究使用 PPO 作為所有「父母模型」與「子代模型」的基底策略網路。

2.2 GA, 遺傳演算法:

遺傳演算法（GA）是模仿自然演化過程的啟發式搜尋方法，核心思想包括選擇、交配與突變。其基本流程如下：

1. 隨機初始化多組（族群）
2. 根據適應度函數定義每個個體的表現
3. 根據適應度進行選擇，保留優秀個體
4. 執行交配與突變，產生新一代族群
5. 重複以上步驟直到收斂

其數學抽象可表示為：

$$P_{t+1} = \text{Mutation}\Big(\text{Crossover}\big(\text{Selection}(\text{Pt})\big)\Big)$$

2.3 神經演化

神經演化將 GA 的演化概念導入到神經網路訓練中，以族群演化直接優化網路參數 θ：

$$\theta_{t+1} = \theta_t + \eta \cdot \triangle_{evolve}$$

其中$\triangle_{evolve}$代表由交配與突變所產生的權重變化，η為控制演化強度的比例係數。這種方法能有效促進模型多樣性與策略探索能力，在強化學習（RL）領域中，常與基於梯度的方法（如 PPO）結合形成「演化式強化學習」架構。

2.4 模型合併與知識蒸餾:

知識蒸餾將教師模型的動作分佈傳遞給學生模型：

$$q_i = \frac{exp\left({}^{z_i}/_{T}\right)}{\sum j\, exp\left({}^{z_j}/_{T}\right)}$$

蒸餾損失使用 KL 散度：：

$$\mathcal{L}_{KD} = T^2 \cdot D_{KL}\left(q_{T(teacher)} || q_{T(student)}\right)$$

與任務交叉熵結合：

$$\mathcal{L}_{total} = (1-\lambda)\mathcal{L}_{CE} + \lambda\mathcal{L}_{KD}$$

在本研究中，知識蒸餾被用於「父母策略 → 子代策略」的知識傳遞階段，使子代在初始化時即具備穩定且具遷移性的策略分佈，並配合多教師信任度權重進行加權學習。

第參章 研究方法

本章將系統性地說明本研究所提出之 ga 的整體設計與運作流程。本研究將策略網路視為「個體」，透過族群初始化、適應度評估、父母挑選、權重交配、離線蒸餾強化、以及線上強化學習微調等多階段機制，使族群能在多世代迭代中逐步累積性能並產生優勢後代。整體流程如圖 3.1 所示，本研究因此建立了一套完整的雙通道演化式強化學習架構（DCFN-GA）。

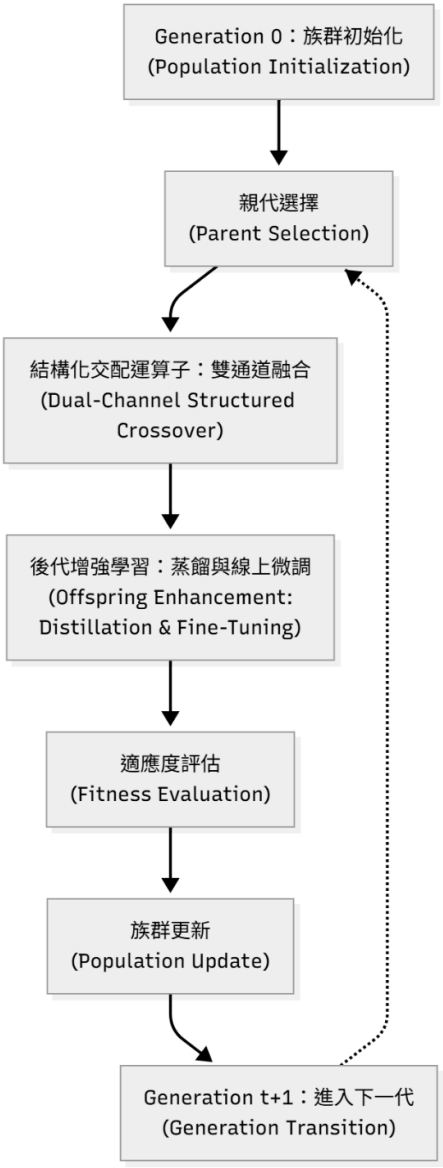

圖 3.1 整體架構

3.1 族群初始化

本研究以 PPO 演算法於 BipedalWalkerC 環境中訓練多個專家代理，每位代理皆使用不同的隨機種子與課程式訓練機制，形成行為風格各異的策略。這些模型組 Generation0 的初始族群，並作為後續 GA 演化的來源個體。

3.2 親代選擇（Parent Selection）

在族群初始化後，本研究於每一世代中根據模型於測試階段的表現，從族群中選擇若干個體作為下一階段交配之父母模型。為確保遺傳演化過程的穩定性與效率，本研究採用菁英保留式選擇策略，選擇 100 次測驗平均報酬最高 top k，同時使前兩名父母直接保留至下一代，以維持族群的策略連續性與基因穩定性。

3.3 結構化交配與子代增強

傳統 GA 在深度網路上進行權重交配時容易造成策略崩潰。
為此，本研究提出：

- DCFN 交配運算子
- 子代增強機制（初始化 → 蒸餾 → 微調）

使交配後的子代得以穩定收斂、吸收父母策略並產生創新行為。

3.3.1 雙通道融合網路

DCFN 是本研究的 GA 交配運算子。

核心理念是獲取父母各半的權重，在每一層中建立三種語意一致的結構區域：

(1) 純淨通道

- 純父通道：直接複製父模型權重
- 純母通道：直接複製母模型權重

(2) 交叉通道

位於純父與純母通道之間，由新參數初始化，負責「策略融合」「特徵協同」「策略創新」

DCFN 的子代權重表示如下：

$$W_{child} = [W_{f(1-32)} | W_{cross} | W_{m(33-64)}]_{-\{dim=-1\}}$$

此設計能避免語意錯配，並使父母特徵在同一語意空間中對齊。

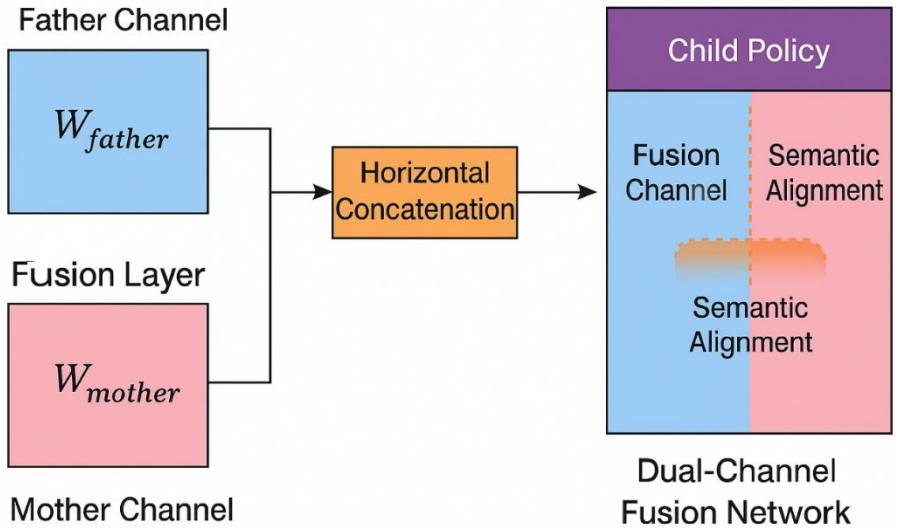

3.3.2 交叉通道初始化

交叉通道作為父母策略的過渡層，若初期權重過大或未對齊，易使子代策略立即崩潰。因此本研究以「完全歸零」或「微小隨機值」初始化，使其以中性狀態開始學習

- 完全歸零初始化:

  交叉權重設為全 $\left(W_{\text{cross}}^{(0)} = 0\right)$，使模型初期僅依賴父母策略輸出。

- ・微小隨機初始化:

  權重以極小標準差隨機分布初始化，例如 $W_{\text{cross}}^{(0)} \sim \mathcal{N}(0, 10^{-3})$。

3.3.3 離線知識蒸餾

交配後子代雖繼承父母特徵，但語意仍不一致，因此需先進行蒸餾校正

- 蒸餾目標與訓練設定:

  「交叉通道」進行參數更新，而父母的「純淨通道」保持凍結，以避免離線蒸餾破壞原始父母策略的結構性特徵。以軟加硬蒸餾損失讓子代不會過於相似父母。

- 蒸餾資料建構:

  離線蒸餾使用多個父母模型於環境中蒐集的資料集，為避免不同教師策略間的矛盾，本研究採用多教師信任度加權，

3.3.4 線上學習:

在本階段中，子代於 BipedalWalkerCustom 環境中進行 PPO 訓練。為兼顧策略穩定性與探索能力，本研究採用以下兩項機制：

(1) 軟凍結梯度控制

僅對交叉通道進行正常梯度更新，而純淨通道只接受極小梯度更新。

(2) 課程式強化學習

採用遞進式難度設定，從低難度地形開始訓練；當平均報酬超過 250 分後，自動提升難度，最高到 1.0。

3.3.5 自動化超參數優化（HPO）

採用 Optuna 套件進行自動化超參數搜尋。將模型在測試階段的平均報酬與可達難度提升幅度 作為評估指標其具體計算方式如下：

$$Score = \text{MeanReward}_{100} + (\text{FinalDifficulty} - \text{InitialDifficulty}) \times 250$$

3.4 適應度評估

本研究以重複測試 100 次所得之平均報酬作為唯一且主要的適應度指標。

3.5 族群更新

每一世代採用固定族群大小，並透過三項機制完成族群更新。

(1) 菁英保留

每一世代選取適應度最高的前 k 名模型直接保留至下一代，以避免優秀策略因交配或訓練波動而被淘汰，確保族群性能不退化。

(2) 父母回流

上一代的 Top-2 父母模型會自動加入下一代族群池。

(3) 子代篩選

所有候選個體依適應度排序後，取前 P 名作為下一代族群：

$$P_{t+1} = Top(E_t \cup R_t \cup C_t)$$

其中 P 為族群大小，E_t為菁英個體，R_t為父母回流個體，Ct 為本世代子代。

第肆章 實驗設計與結果分析

4.1 實驗環境與設定:

本研究採用 Proximal Policy Optimization（PPO）作為基礎演算法，並於自訂環境 BipedalWalkerCustom-v0 中訓練多組父母模型，分別使用不同的隨機種子碼進行訓練，各自 1e7 steps。訓練完成後，再依照「雙通道融合交配法」進行權重交配與後續蒸餾訓練。

4.1.1 硬體與軟體環境

實驗皆於本地電腦上進行，環境配置如下：

- 作業系統: Window11
- GPU : NVIDIA RTX 4090 24GB
- CPU : Intel Core i9-13900K
- 記憶體 : 64GB
- CUDA : 12.1
- 主要套件版本: PyTorch 2.3.0、Gymnasium 0.29、Stable-Baselines3 2.3、Optuna 3.6、NumPy 1.26

4.1.2 訓練環境與模型架構

實驗採用 BipedalWalkerCustom-v0 為主要訓練與測試環境，該環境基於經典 BipedalWalker 任務進行擴展父母模型與子代模型均採用 Stable-Baselines3 所提供之 PPO 策略網路架構，Actor 與 Critic 各 2 層 MLP、隱藏層 64 × 2、啟動函數 tanh

4.1.3 參數設定

採用 Optuna 進行自動化超參數搜尋，蒸餾階段固定設定為 1 epoch, 約 100,000 steps，以確保不同個體間蒸餾訓練公平一致。

4.1.4 評估方法

- 冠軍子代模型效能評估

  各模型皆初始條件下進行推論，並取平均與方差以衡量穩定性。最終於報告中以效能比較直條圖呈現。

- 系統性消融研究

  移除特定機制後重新訓練，以比較其性能差異，驗證此架構必要性。

- 泛化能力分析

  從難度 0-1.0，測 100 次平均獎勵以長條圖呈現。

- 內部結構與行為分析
  - 權重演化觀察

    繪製三者（父、母、子）對應層的 權重熱力圖，視覺化證明子代策略的「自發形成」與「知識融合」過程。

  - 行為相似度分析

    透過動作分佈圖分析父母與子代的決策差異。

- GA 效果評估

  透過比較交配前後的平均回報提升幅度、跨難度穩定性變化與策略分佈差異，評估遺傳交配對模型性能與策略多樣性的實際貢獻，驗證 GA 在融合與創新中的有效性。

國立中興大學進修學士班 NCHU Continuing Bachelor Program Since 1968

4.2 冠軍模型效能評估

為驗證所提出「雙通道融合交配法」在性能上的實際效益，本節比較父母模型與最終子代模型之平均表現與穩定性。我們從圖 4.2，可以得知經過經由雙通道融合與蒸餾訓練後，所交配出來的模型對比父母平均提升約 5.45%。同時標準差下降約 11%顯示該方法能有效整合父母策略特徵，提升整體穩定性與泛化能力。

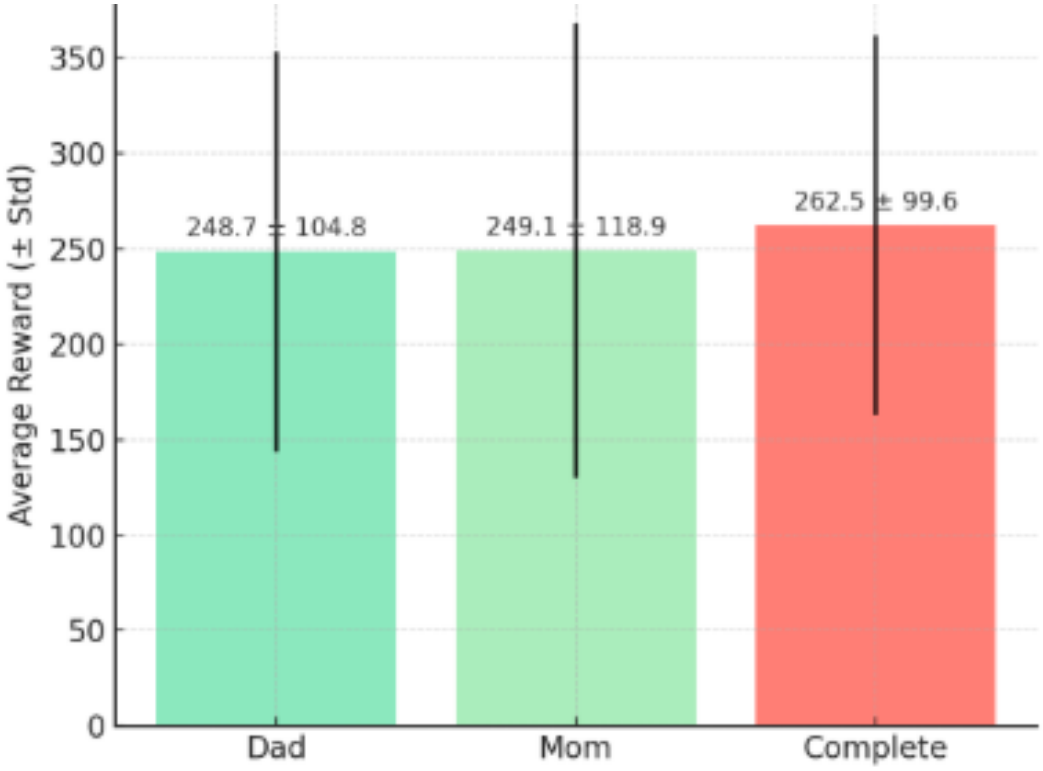

圖 4.2 冠軍模型效能評估

4.3 系統性消融研究

圖 4.3 顯示本研究的模型交配訓練方法能有效提升子代表現。未經蒸餾的初期模型完全崩潰，而加入離線蒸餾後性能大幅改善，是最關鍵的穩定化階段。移除凍結純淨通道或差異化梯度亦使表現明顯下降，顯示保留父母策略與控制通道學習的重要性。

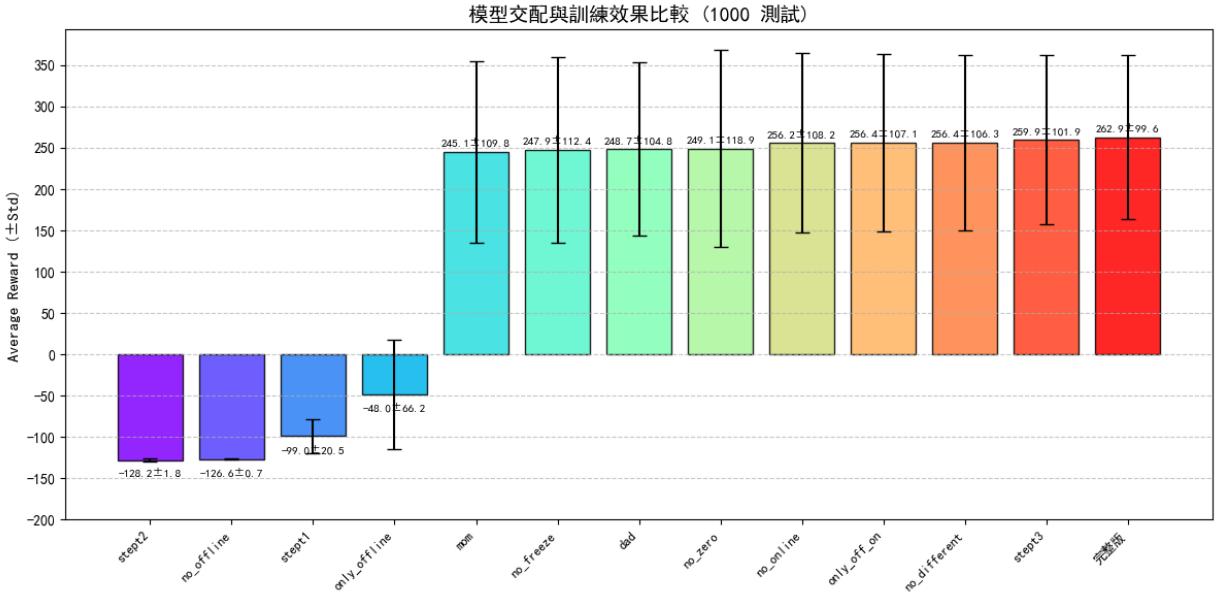

圖 4.3 模型與訓練效果比較

4.4 泛化能力分析

跨難度測試結果顯示，子代模型在所有難度下皆優於父母模型，低至中等難度（0.2－0.6）平均回報提升約 5－10%，未包含的高難度 0.9 與 1.0，子代仍維持最高表現，證明其具備外推泛化能力。雙通道融合成功整合父母策略並發展更具適應性的行為。

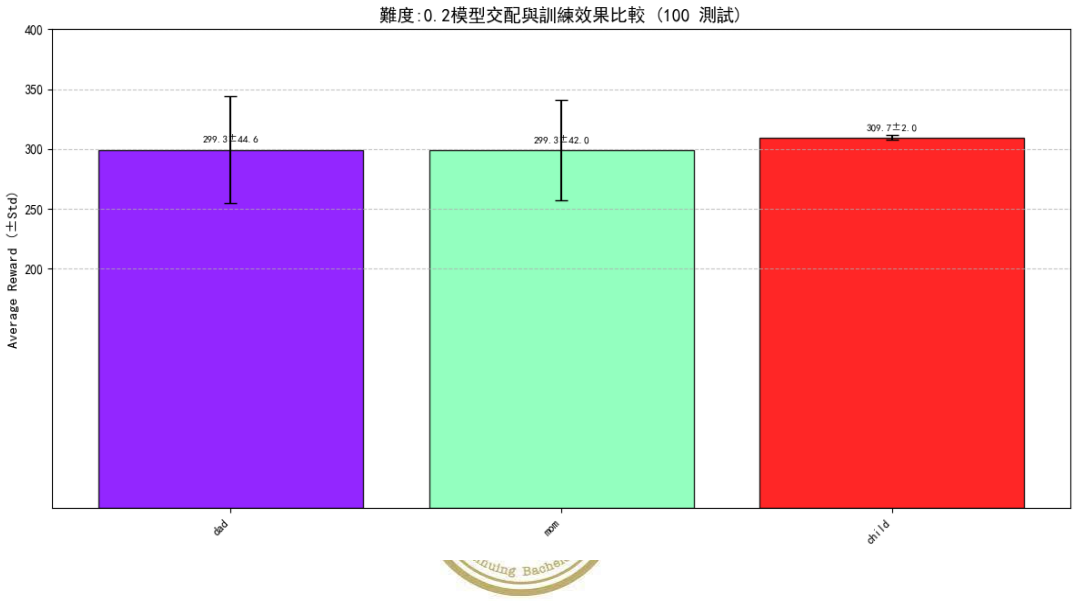

圖 4.4 a 度 0.2 模型交配與訓練效果

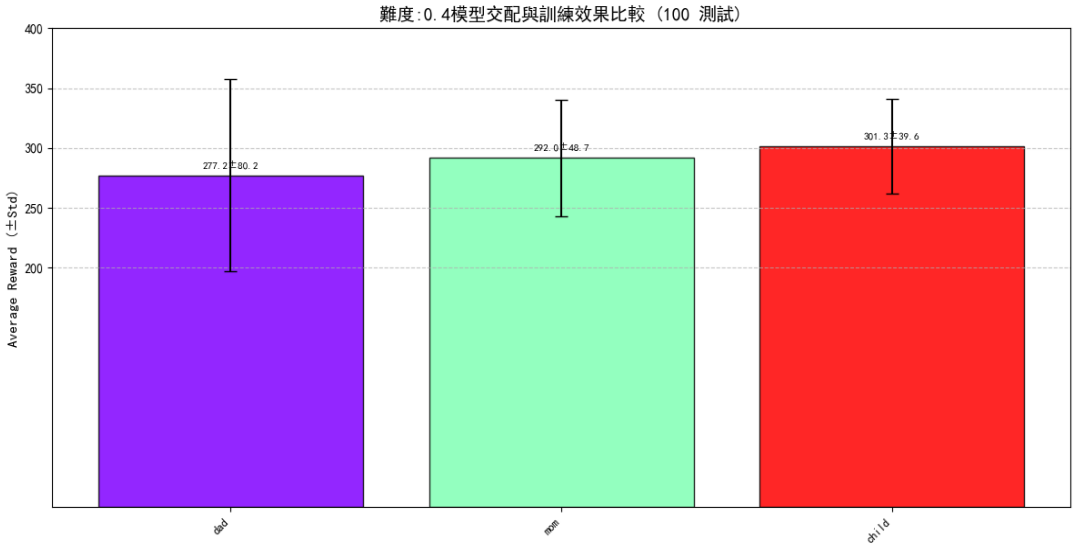

圖 4.4 b 難度 0.4 模型交配與訓練效

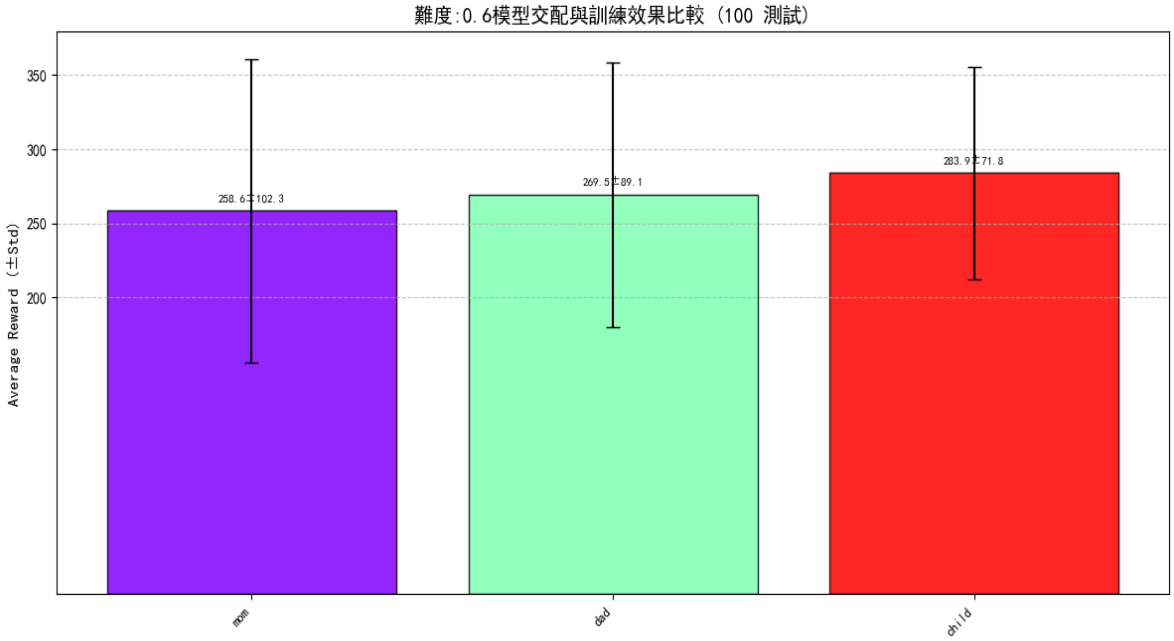

圖 4.4 c 難度 0.6 模型交配與訓練效果比較

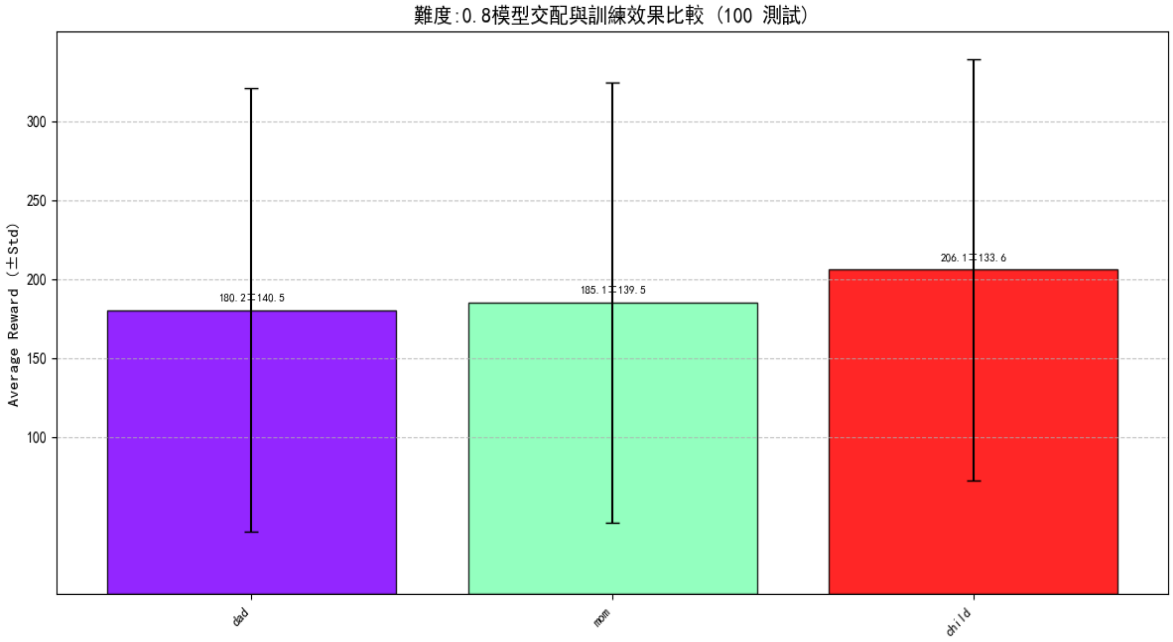

圖 4.4 d 難度 0.8 模型交配與訓練效果比較

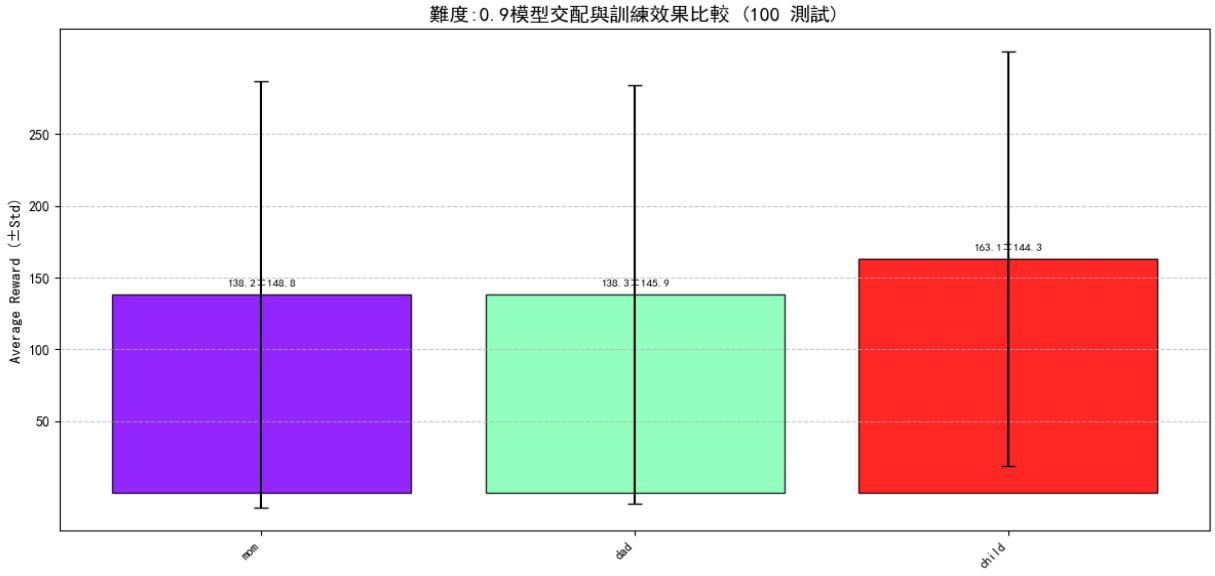

圖 4.4e 難度 0.9 模型交配與訓練效果比較

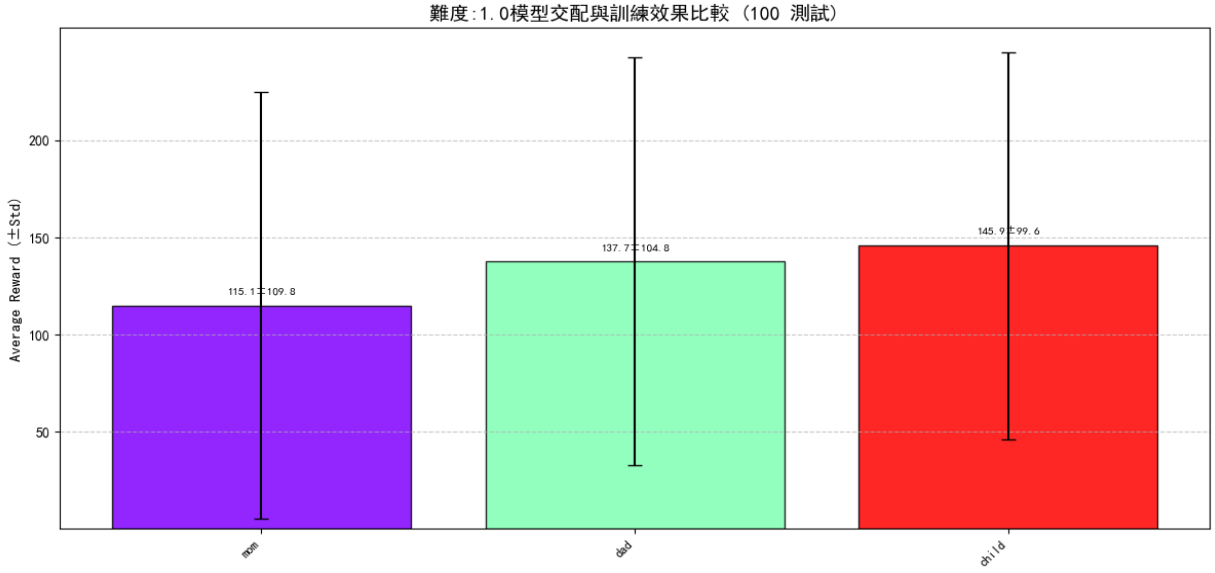

圖 4.4f 難度 1.0 模型交配與訓練效果比較

4.5 行為分析

由分布圖可知父、母、子三者的動作機率分佈，不一樣子代會發展出不一樣的策略。

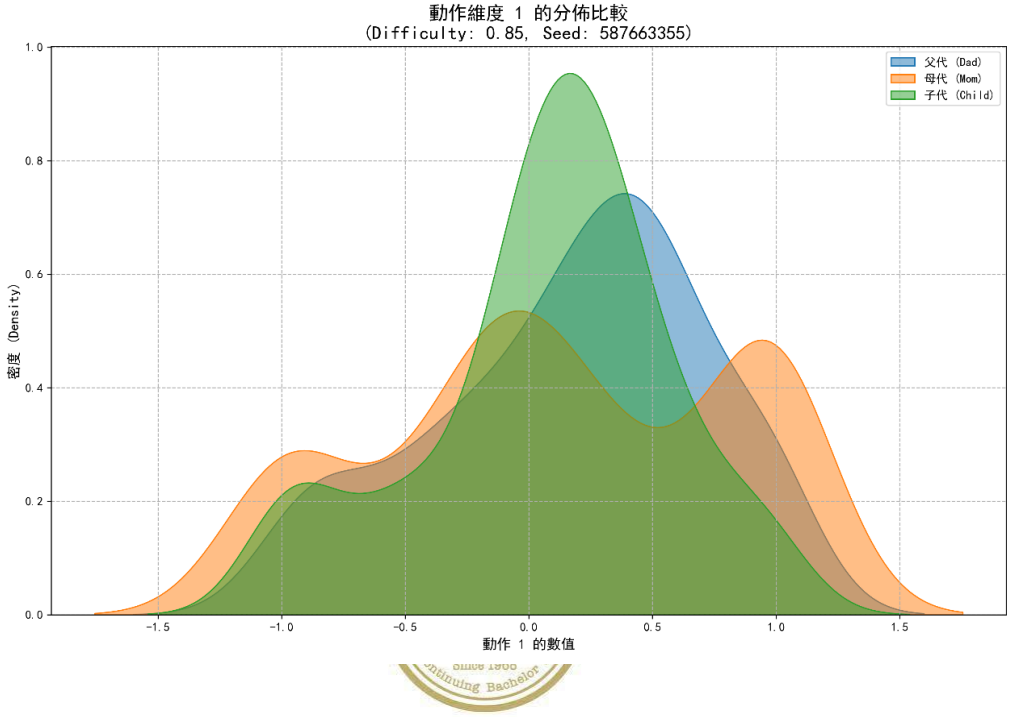

圖 4.6.3.1:動作維度 1 分佈比

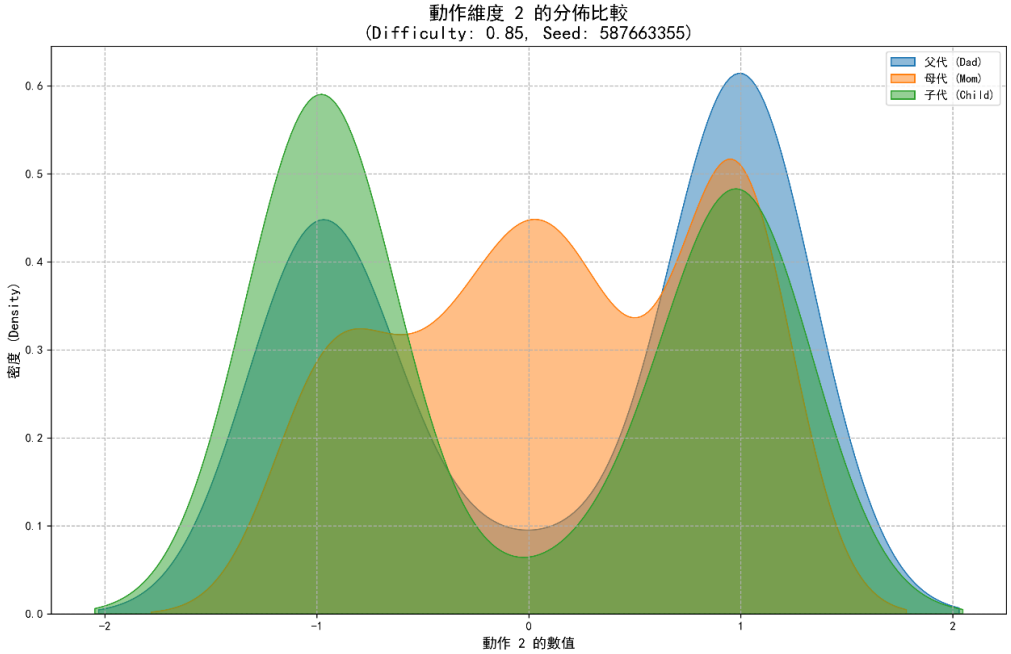

圖 4.6.3.2:動作維度 2 分佈比

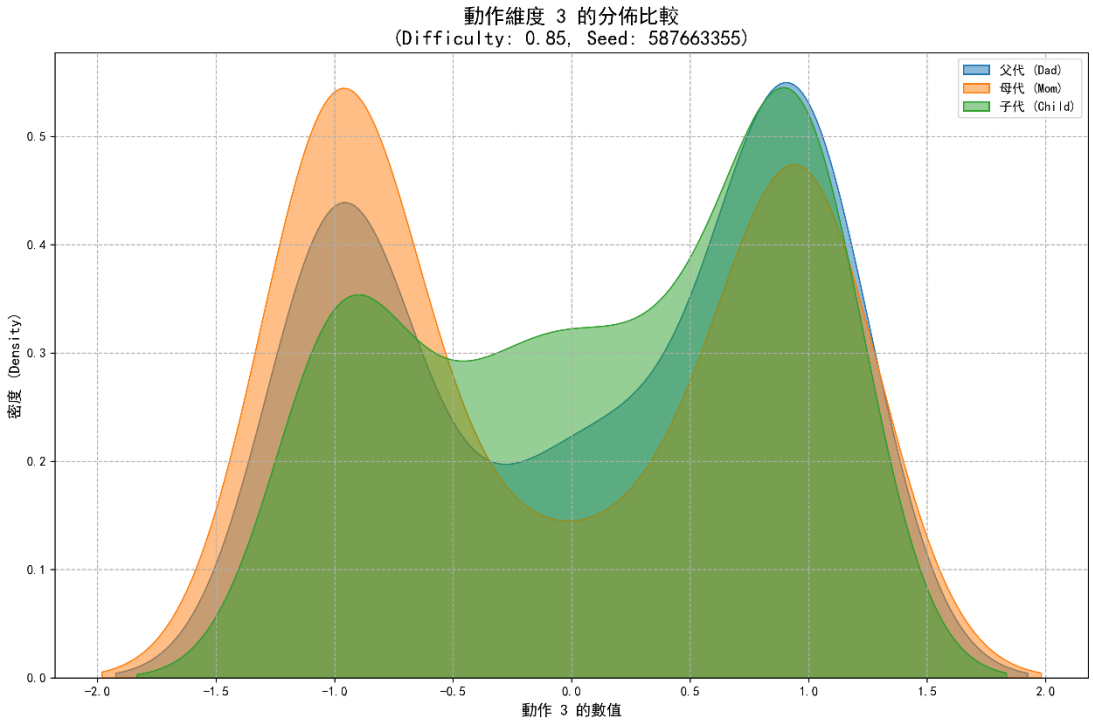

圖 4.6.3.3:動作維度 3 分佈比較

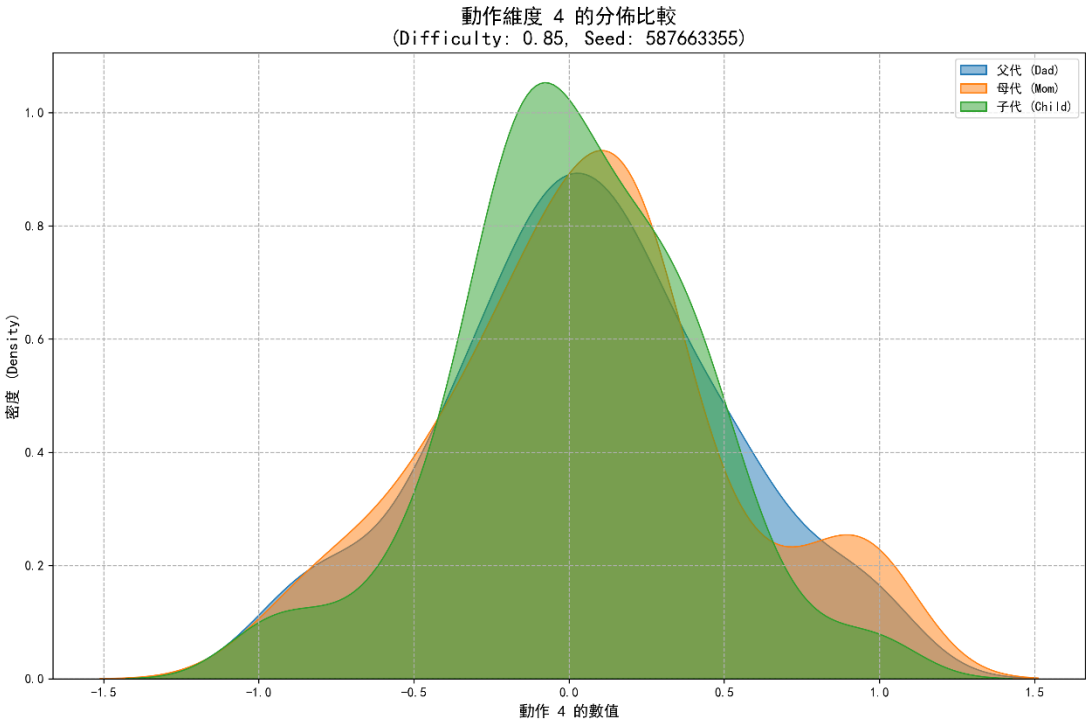

圖 4.6.3.4:動作維度 4 分佈比較

4.6 多世代演化結果分析

本研究針對雙通道融合 GA（DCFN-GA）進行多世代分析，結果顯示族群性能隨世代穩定提升。成功率由 Gen0 的 52% 提升至 Gen5 的 75%(圖 4.6.1)，證明融合與蒸餾能在首代就產生高品質子代，而 GA 的篩選與微調則持續強化策略。策略穩定度也逐代改善，獎勵標準差自 136 降至 123(圖 4.6.2)，代表行為一致性提升、崩潰策略減少。獎勵分布亦呈現逐步收斂，Gen0→Gen1 中位數大幅上升，四分位距縮小，而 Gen2～Gen5 更呈現離群點減少與分布集中(圖 4.6.3)，象徵子代策略逐漸成熟。族群規模方面，Pop=5 早期收斂較快，但 Pop=10 在後期表現更佳且更穩定，符合 GA 中大族群具較高探索能力與長期性能的特性(圖 4.6.4)。整體而言，DCFN-GA 能讓策略於第一代迅速穩定，並在跨世代的演化過程中持續提升均值、降低變異，最終形成成熟且具泛化力的策略族群。

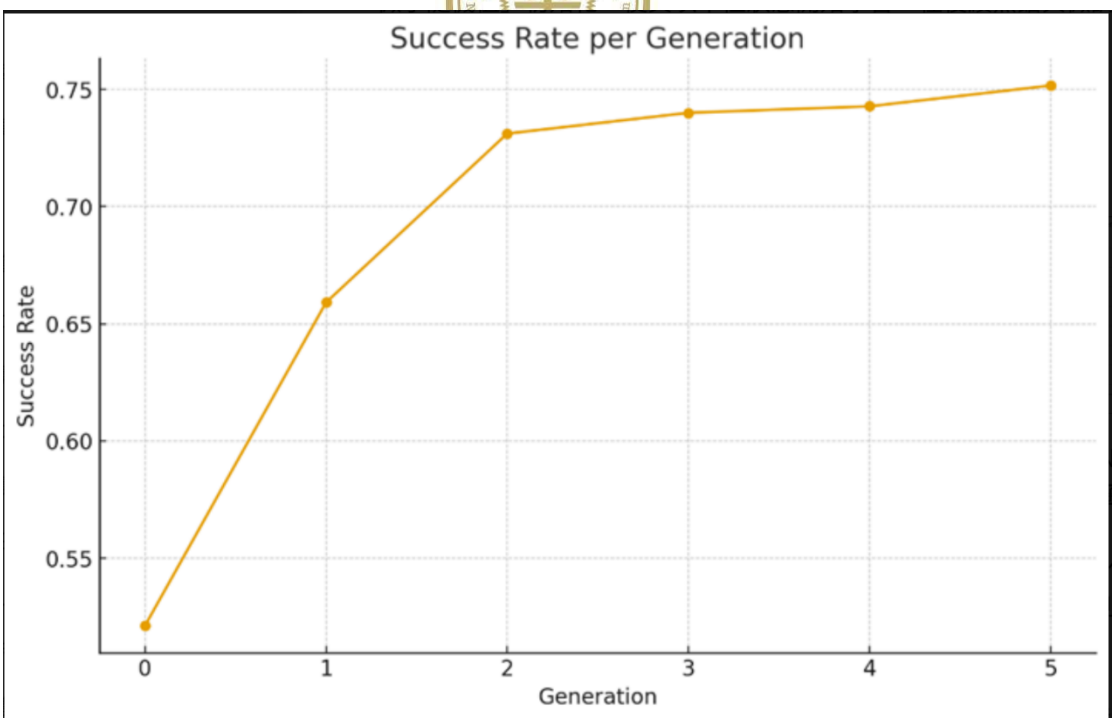

圖 4.6.1:Ga 成功率比較

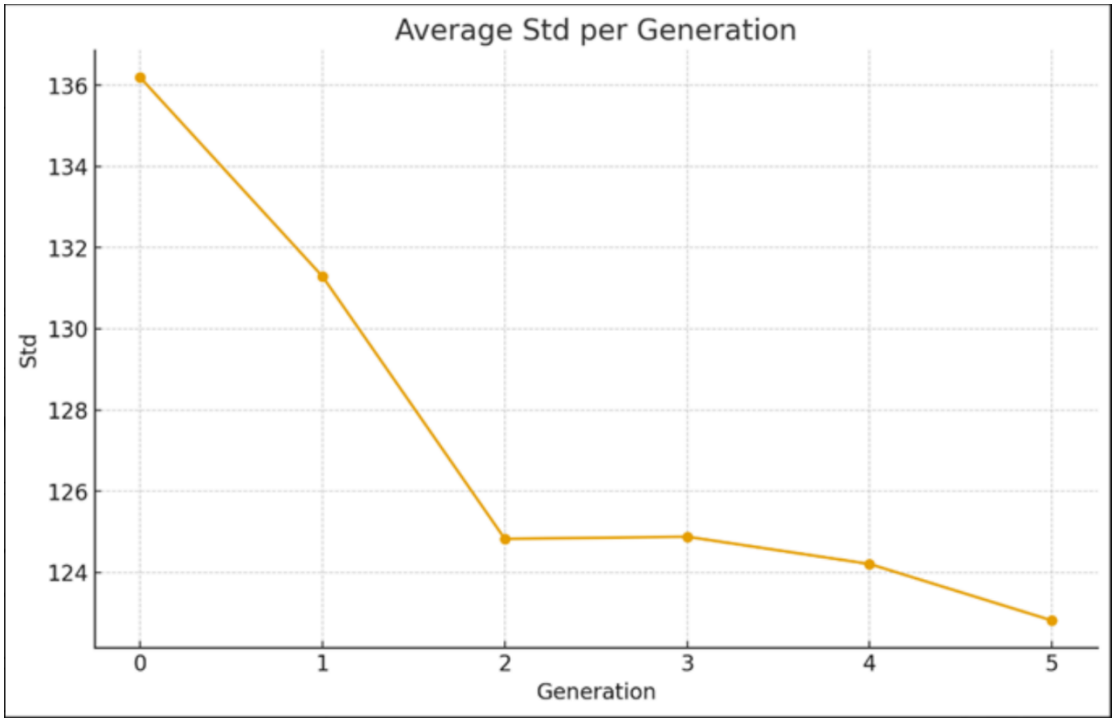

圖 4.6.2:個世代標準差比較

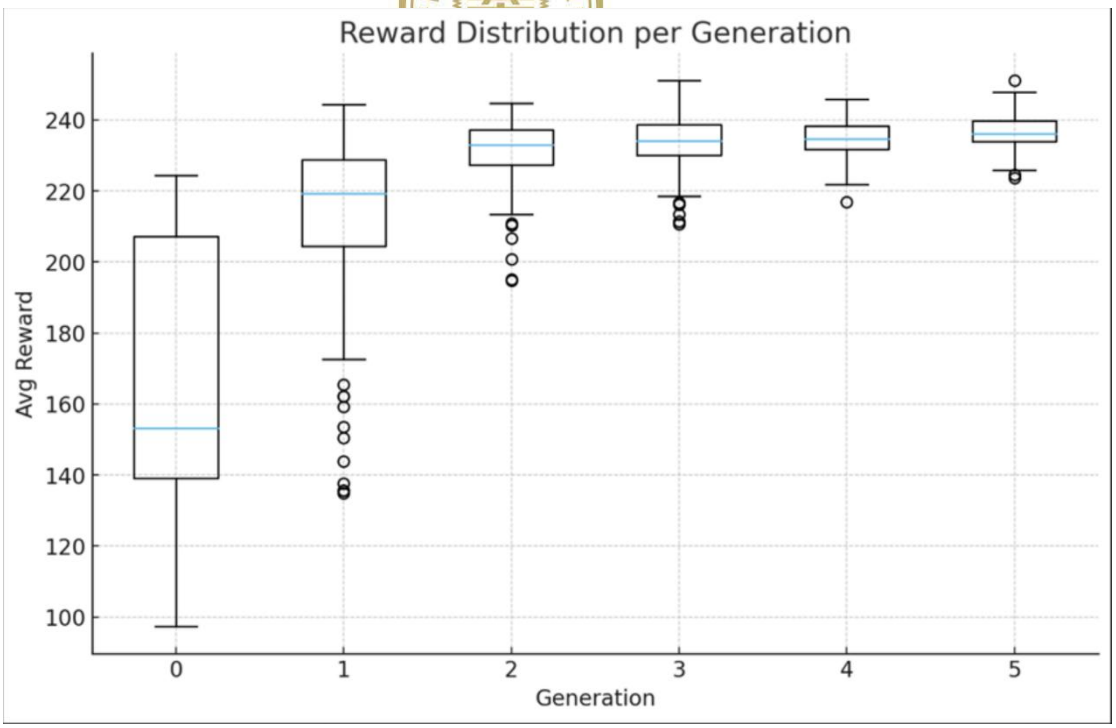

圖 4.6.3:個世代獎勵分布比較

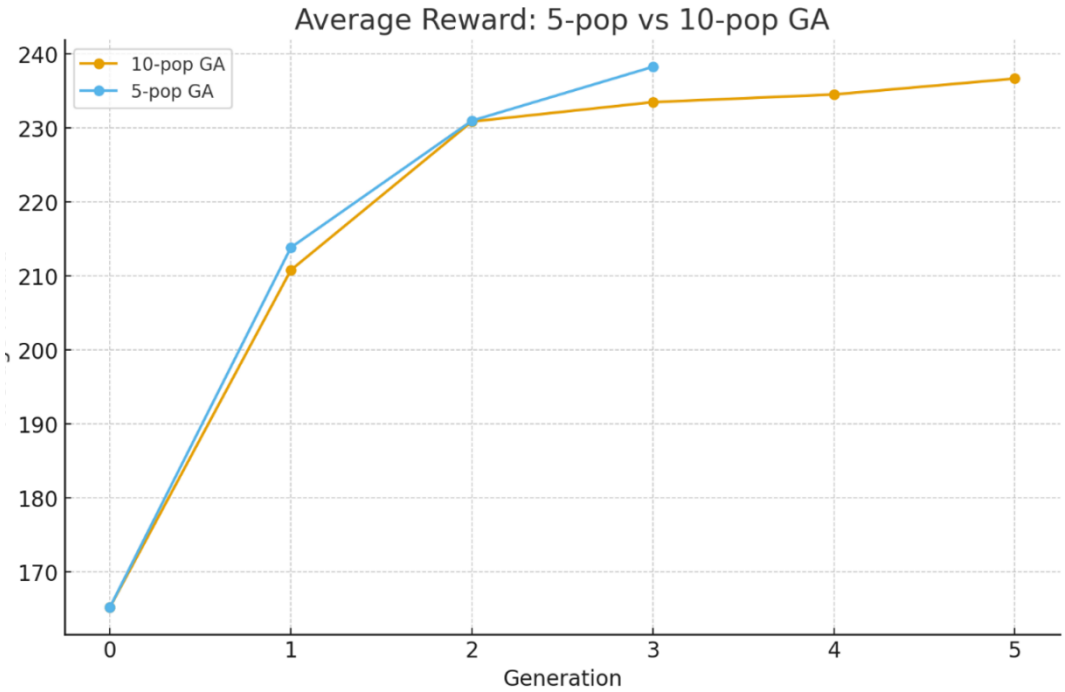

圖 4.6.2: 族群規模表現比較圖

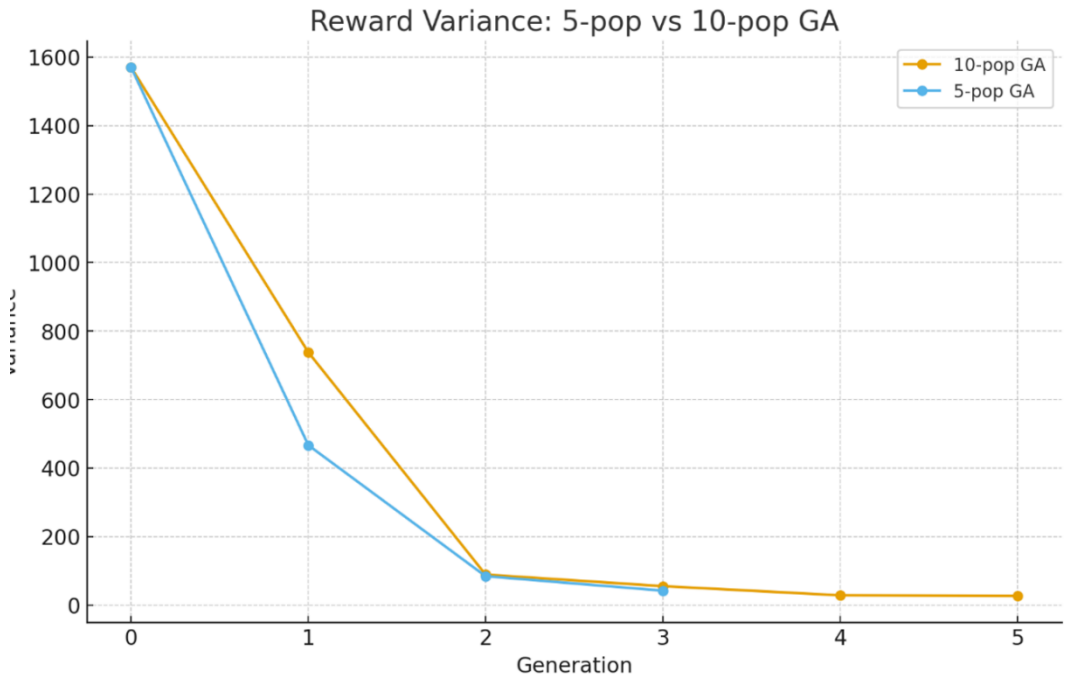

圖 4.6.2: 族群穩定性比較圖

第伍章 結論與未來工作

5.1 結論

本研究以遺傳演算法為核心，提出可多世代運作的雙通道演化式強化學習架構（DCFN-GA）。純淨通道負責穩定繼承父母策略，而交叉通道承擔策略創生，並透過初始化、蒸餾與微調逐步形成新行為。實驗顯示，多世代 GA 的選擇與篩選機制能持續提升族群性能，最終獲得兼具穩定性與泛化力的子代策略。

5.2 研究貢獻

本研究的主要貢獻可歸納如下：

- **提出新穎的雙通道融合的 GA 設計**

  提出雙通道融合的 GA 設計，將策略網路分為負責穩定繼承的「純淨通道」與負責策略創生的「交叉通道」，形成具結構化遺傳特性的交配機制。

- **設計並驗證完整的兩階段訓練流程**

  本研究設計了一個兼顧穩定性與創新的雙階段訓練機制，確保模型在融合過程中能有效繼承父母知識，同時逐步建立新的策略特徵：

- **建立系統性的消融研究與行為層面分析**

  透過消融實驗、權重熱圖、權重差分與動作分佈比較，證實子模型非簡單平均父母策略，而是在繼承基礎上產生新的行為模式

- **實現高性能與泛化兼具的 RL Agent:**

  子模型在多數難度下均優於父母，並在未見過的地形保持較低變異性，證實本架構能強化外推泛化能力。有效縮短模型訓練時間與開發成本:

5.3 未來展望

可發展可學習的動態融合權重，以自適應調整繼承與創新比例，並探索不同演算法或異構網路間的交配機制，提升策略創新、穩定性與泛化能力。

第陸章 參考資料

[1] Model Fusion via Optimal Transport Singh & Jaggi (NeurIPS 2020)

[2] Bridging Evolutionary Algorithms and Reinforcement Learning: A Comprehensive Survey on Hybrid Algorithms Pengyi Li, Jianye Hao, Hongyao Tang, Xian Fu, Yan Zheng, Ke Tang

[3]Schulman, J. et al., Proximal Policy Optimization Algorithms, arXiv:1707.06347, 2017.

[4]Sutton, R. S., & Barto, A. G., Reinforcement Learning: An Introduction (2nd ed.), MIT Press, 2018.

[5] Mnih, V. et al., Human-level control through deep reinforcement learning, Nature, 518(7540), 529–533, 2015.

[6] Lillicrap, T. P. et al., Continuous control with deep reinforcement learning, ICLR, 2016.

[7] Stanley, K. O., & Miikkulainen, R., Evolving Neural Networks through Augmenting Topologies, Evolutionary Computation, 10(2), 99–127, 2002.

[8] Stanley, K. O. et al., Designing neural networks through neuroevolution, Nature Machine Intelligence, 1(1), 24–35, 2019.

[9] Real, E. et al., Regularized Evolution for Image Classifier Architecture Search, AAAI 2019.

[10] Such, F. P. et al., Deep neuroevolution: Genetic algorithms are a competitive alternative for training deep neural networks for reinforcement learning, arXiv:1712.06567, 2017.

[11] Hinton, G., Vinyals, O., & Dean, J., Distilling the knowledge in a neural network, arXiv:1503.02531, 2015.

[12] Rusu, A. A. et al., Policy distillation, arXiv:1511.06295, 2015.

[13] Zhang, Y., & Song, J., Improving policy distillation in reinforcement learning via adaptive temperature, NeurIPS Workshop on Deep RL, 2020.

[14] Zhao, T. et al., Model Fusion via Knowledge Distillation for Robust Reinforcement Learning, IEEE TNNLS, 32(9), 4041–4053, 2021.

[15] Bengio, Y. et al., Curriculum learning, ICML, 2009.

[16] Portelas, R. et al., Automatic curriculum learning for deep RL: A short survey, arXiv:2003.04664, 2020.

[17] Khadka, S., & Tumer, K., Evolution-guided policy gradient in reinforcement learning, NeurIPS 2018.

[18] Gangwani, T., & Peng, J., Policy optimization by genetic distillation, arXiv:1805.10531, 2018.

[19] Jaderberg, M. et al., Population based training of neural networks, arXiv:1711.09846, 2017.

[20] Raffin, A. et al., Stable-Baselines3: Reliable reinforcement learning implementations, JMLR, 22(268), 1–8, 2021.

[21] Akiba, T. et al., Optuna: A next-generation hyperparameter optimization framework, KDD, 2623–2631, 2019.

[22] Brockman, G. et al., OpenAI Gym: A toolkit for developing and comparing reinforcement learning algorithms, arXiv:1606.01540, 2016.